



**UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
CURSO DE ENGENHARIA DE COMPUTAÇÃO**

Al. Marisa de Fátima Girão Linhares - 581121
Al. Moisés Barbosa Miranda de Carvalho - 582969
Al. José Gustavo Cavalcante Barata - 585644
Al. Álvaro Mendonça Vasconcelos Nunes Campelo - 588071

HOMEWORK 1

Professora Michela Mulas

FORTALEZA, CE
2026

Questão 1: Construção do conjunto de dados que será utilizado

Nessa questão é necessário criar uma amostra dos dados gerais que será utilizada a partir de agora pelo grupo na resolução das questões seguintes. Nomeado de `data_group`, ele contém 300 linhas consecutivas dos dados completos. A escolha dessas linhas se deu a partir de uma expressão utilizando a maior matrícula entre os integrantes do grupo. Abaixo segue como foi feita essa etapa:

- `M` recebe a maior matrícula, 588071, que pertence ao aluno Álvaro Campelo;
- `r` recebe $1 + (M \bmod 100)$; $r = 1 + (588071 \bmod 100) \Rightarrow r = 1 + 71 \Rightarrow r = 72$;
- `data_group` irá conter 300 linhas, iniciando na linha 72 e finalizando na linha 371 dos dados originais;

Trecho do arquivo que contém os dados da linha 1 do `data_group`:

72	72	2011-03-13	1	1	15.8	982	1435
----	----	------------	---	---	------	-----	------

Trecho do arquivo que contém os dados da linha 300 do `data_group`:

371	371	2012-01-06	1	1	13.7	307	3791
-----	-----	------------	---	---	------	-----	------

Código em R:

```
# dataset direto do GitHub
url_dados <- "https://raw.githubusercontent.com/marisalinhares/homework_1_estatistica_j
↵ /refs/heads/main/HW1_bike_sharing.csv"
dados_completos <- read.csv(url_dados)

M <- 588071
r <- 1 + (M%%100)
cat("Valor de r:", r, "\n")

data_group <- dados_completos[r:(r+299), ]
dim(data_group)

primeira_linha <- data_group$dteday[1]
ultima_linha <- data_group$dteday[300]

cat("Primeira linha:", primeira_linha, "\n")
cat("Última linha:", ultima_linha, "\n")
```

Explicação do código: O arquivo completo é lido direto do repositório do grupo no GitHub, o que permite rodar o código em qualquer máquina. Em seguida, `M` e `r` são definidos como no enunciado e o `data_group` é extraído com as linhas `r` a `r+299`, usando `dim()` e `cat()` para conferir as dimensões e as datas da primeira e da última linha com os valores obtidos à mão.

Segue a saída do código:

```

> M <- 588071
> r <- 1 + (M%%100)
> cat("Valor de r:", r, "\n")
Valor de r: 72
> data_group <- dados_completos[r:(r+299), ]
> dim(data_group)
[1] 300 8
> primeira_linha <- data_group$dteday[1]
> ultima_linha <- data_group$dteday[300]
> cat("Primeira linha:", primeira_linha, "\n")
Primeira linha: 2011-03-13
> cat("Última linha:", ultima_linha, "\n")
Última linha: 2012-01-06

```

Conclusão: os resultados obtidos no R coincidiram com os valores calculados manualmente.

Extra: segue a linha de código que cria `data_group_10`, contendo as primeiras 10 observações do conjunto de dados do grupo:

```
data_group_10 <- data_group[1:10, ]
```

Questão 2: Caracterização e Análise Univariada

Esta questão caracteriza o conjunto de dados `data_group`, construído na Questão 1 (300 observações diárias, de 13/03/2011 a 06/01/2012, com $r = 72$). Conforme solicitado, os cálculos estatísticos foram feitos **primeiro manualmente com as 10 primeiras observações**, depois verificados no R, e só então o mesmo código foi aplicado às 300 observações.

2.1 Caracterização das variáveis

Código em R:

```

data_group$total_user <- data_group$casual + data_group$registered
data_group_10 <- data_group[1:10, ]
dim(data_group_10)

# Classificação das variáveis, categorias e valores ausentes
str(data_group)
summary(data_group)

# Categorias das variáveis categóricas
table(data_group$season)      # 1, 2, 3, 4
table(data_group$weathersit)   # 1, 2, 3

# Período observado
range(as.Date(data_group$dteday))

# Valores ausentes por variável
colSums(is.na(data_group))

# Unidades / faixa de valores da temperatura
summary(data_group$temp)

```

Saída:

```
[1] 10 9
'data.frame':      300 obs. of  9 variables:
 $ X      : int  72 73 74 75 76 77 78 79 80 81 ...
 $ instant : int  72 73 74 75 76 77 78 79 80 81 ...
 $ dteday  : chr  "2011-03-13" "2011-03-14" "2011-03-15" "2011-03-16" ...
 $ season  : int   1 1 1 1 1 1 1 1 2 2 ...
 $ weathersit: int   1 1 2 2 1 1 1 1 2 1 ...
 $ temp    : num  15.8 13.3 13 15 17 22.1 19.4 13.6 17.6 18.1 ...
 $ casual  : int  982 359 289 321 424 884 1424 1047 401 460 ...
 $ registered: int 1435 1687 1767 1871 2320 2355 1693 1424 1676 2243 ...
 $ total_user: int 2417 2046 2056 2192 2744 3239 3117 2471 2077 2703 ...

      X      instant      dteday      season
Min.   : 72.0   Min.   : 72.0   Length:300   Min.   :1.000
1st Qu.:146.8   1st Qu.:146.8   Class :character 1st Qu.:2.000
Median :221.5   Median :221.5   Mode  :character Median :3.000
Mean   :221.5   Mean   :221.5                   Mean   :2.823
3rd Qu.:296.2   3rd Qu.:296.2                   3rd Qu.:4.000
Max.   :371.0   Max.   :371.0                   Max.   :4.000

      weathersit      temp      casual      registered      total_user
Min.   :1.000   Min.   : 4.40   Min.   : 50.0   Min.   : 451   Min.   : 627
1st Qu.:1.000   1st Qu.:16.65   1st Qu.: 395.0   1st Qu.:2478   1st Qu.:3137
Median :1.000   Median :22.20   Median : 690.5   Median :3256   Median :4070
Mean   :1.413   Mean   :22.06   Mean   : 787.6   Mean   :3052   Mean   :3840
3rd Qu.:2.000   3rd Qu.:27.90   3rd Qu.: 949.8   3rd Qu.:3772   3rd Qu.:4681
Max.   :3.000   Max.   :34.80   Max.   :3065.0   Max.   :4614   Max.   :6043

      1  2  3  4
25 92 94 89

      1  2  3
189 98 13
[1] "2011-03-13" "2012-01-06"

      X      instant      dteday      season weathersit      temp      casual
      0          0          0          0          0          0          0
registered total_user
      0          0
      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
      4.40  16.65  22.20  22.06  27.90  34.80
```

Explicação e classificação: Foi criada a variável `total_user = casual + registered` (usuários totais por dia). A função `colSums(is.na(data_group))` retornou 0 em todas as colunas, ou seja, não há valores ausentes nas 300 observações. As variáveis foram classificadas assim:

Variável	Tipo	Justificativa / categorias / unidade
instant	Identificador (índice numérico)	Apenas numera os registros; não tem significado quantitativo e não entra nas medidas estatísticas.
dteday	Temporal (data)	Data da observação, de 2011-03-13 a 2012-01-06; possui ordem cronológica.
season	Categórica nominal	Categorias 1 a 4 (pelas datas: 1 = inverno, 2 = primavera, 3 = verão, 4 = outono). Todas ocorrem no grupo.
weathersit	Categórica nominal	1 = céu limpo, 2 = nublado, 3 = chuva fraca. A categoria 4 (chuva forte) não ocorre no grupo.
temp	Numérica contínua	Temperatura em °C, de 4,4 a 34,8 (valores brutos, e não no intervalo $[0, 1]$ que resultaria da divisão por 41 citada no enunciado).
casual, registered, total_user	Numéricas discretas	Contagens; unidade: usuários por dia.

2.2 Cálculo manual com as 10 primeiras observações

Variável analisada: `total_user`. As 10 primeiras linhas do grupo (`instant` 72 a 81):

#	dteday	casual	registered	total_user
1	2011-03-13	982	1435	2417
2	2011-03-14	359	1687	2046
3	2011-03-15	289	1767	2056
4	2011-03-16	321	1871	2192
5	2011-03-17	424	2320	2744
6	2011-03-18	884	2355	3239
7	2011-03-19	1424	1693	3117
8	2011-03-20	1047	1424	2471
9	2011-03-21	401	1676	2077
10	2011-03-22	460	2243	2703

Dados ordenados: 2046, 2056, 2077, 2192, **2417**, **2471**, 2703, 2744, 3117, 3239.

Média: $\bar{x} = \sum x_i / n = 25062 / 10 = \mathbf{2506,2}$

Mediana: com $n = 10$ (par), é a média dos valores nas posições 5 e 6: $(2417 + 2471) / 2 = \mathbf{2444}$

Moda: nenhum valor se repete, então a amostra é **amodal**.

Variância e desvio padrão (amostrais): $s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$. Os desvios ao quadrado somam 1.711.945,6, logo $s^2 = 1.711.945,6 / 9 = \mathbf{190.216,18}$ e $s = \sqrt{190.216,18} = \mathbf{436,14}$.

Quartis (interpolação linear, convenção padrão do R): posição $h = (n - 1) \cdot p + 1$.

- $Q_1: h = 3,25 \rightarrow x_3 + 0,25 \cdot (x_4 - x_3) = 2077 + 0,25 \cdot 115 = \mathbf{2105,75}$
- $Q_2: h = 5,5 \rightarrow \mathbf{2444}$
- $Q_3: h = 7,75 \rightarrow x_7 + 0,75 \cdot (x_8 - x_7) = 2703 + 0,75 \cdot 41 = \mathbf{2733,75}$

- $IQR = Q_3 - Q_1 = 628$

Limites para valores atípicos: inferior = $2105,75 - 1,5 \cdot 628 = 1163,75$; superior = $2733,75 + 1,5 \cdot 628 = 3675,75$. Todas as 10 observações estão entre 2046 e 3239, portanto **não há outliers** nesta subamostra.

Critério low_usage (só para ilustrar): com $Q_1 = 2105,75$, os dias abaixo do limite são 2046, 2056 e 2077, ou seja, 3 de 10 (30%).

Código em R (verificação):

```
x10 <- data_group_10$total_user
n10 <- length(x10)
print(data.frame(instant = data_group_10$instant,
                 dteday = data_group_10$dteday,
                 casual = data_group_10$casual,
                 registered = data_group_10$registered,
                 total_user = x10))

# Média
soma10 <- sum(x10)
media10m <- soma10 / n10
cat("Soma =", soma10, "| Média manual =", media10m, "\n")

# Mediana
x10_ord <- sort(x10)
mediana10m <- (x10_ord[n10 / 2] + x10_ord[n10 / 2 + 1]) / 2
cat("Ordenado:", x10_ord, "\nMediana manual =", mediana10m, "\n")

# Moda
calcular_moda <- function(x) {
  tab <- table(x)
  fmax <- max(tab)
  if (fmax == 1) return(NA) # amodal: nenhum valor se repete
  as.numeric(names(tab)[tab == fmax]) # devolve TODAS as modas (empates)
}
cat("Moda (10 obs.):", calcular_moda(x10), "\n")

# Variância e desvio padrão
desv10 <- x10 - media10m
soma_quad10 <- sum(desv10^2)
var10m <- soma_quad10 / (n10 - 1)
dp10m <- sqrt(var10m)
cat("Soma dos quadrados dos desvios =", soma_quad10,
    "\nVariância amostral manual =", var10m,
    "\nDesvio padrão amostral manual =", dp10m, "\n")

# Versão populacional (divisor n), só para comparar com outras convenções
var10_pop <- soma_quad10 / n10
cat("Variância populacional =", var10_pop, "| DP populacional =", sqrt(var10_pop),
    "\n")

# Quartis
quartil_manual <- function(x, p) {
  xs <- sort(x); n <- length(xs)
  h <- (n - 1) * p + 1
  inf <- floor(h)
  xs[inf] + (h - inf) * (xs[min(inf + 1, n)] - xs[inf])
}
Q1_10m <- quartil_manual(x10, 0.25)
Q2_10m <- quartil_manual(x10, 0.50)
```

```

Q3_10m <- quartil_manual(x10, 0.75)
IQR10m <- Q3_10m - Q1_10m
lim_inf10m <- Q1_10m - 1.5 * IQR10m
lim_sup10m <- Q3_10m + 1.5 * IQR10m
cat("Q1 =", Q1_10m, "| Q2 =", Q2_10m, "| Q3 =", Q3_10m, "| IQR =", IQR10m,
    "\nLimites:", lim_inf10m, "e", lim_sup10m,
    "\nOutliers:", x10[x10 < lim_inf10m | x10 > lim_sup10m], "\n")

metade_inf <- x10_ord[1:(n10 / 2)]
metade_sup <- x10_ord[(n10 / 2 + 1):n10]
cat("Mediana das metades: Q1 =", median(metade_inf), "| Q3 =", median(metade_sup),
    "\n")

cat("Dias com total_user < Q1 (10 obs.):", sum(x10 < Q1_10m), "de", n10, "\n")

# VERIFICAÇÃO no R (funções nativas) e comparação
verificacao10 <- data.frame(
  medida = c("Média", "Mediana", "Variância (n-1)", "Desvio padrão (n-1)", "Q1", "Q2",
    "\nQ3", "IQR"),
  manual = c(media10m, mediana10m, var10m, dp10m, Q1_10m, Q2_10m, Q3_10m, IQR10m),
  R = c(mean(x10), median(x10), var(x10), sd(x10),
    quantile(x10, 0.25), quantile(x10, 0.50), quantile(x10, 0.75), IQR(x10))
)
verificacao10$diferenca <- verificacao10$manual - verificacao10$R
print(verificacao10, row.names = FALSE)

# Efeito da convenção de cálculo dos quartis (tipos do quantile())
sapply(c(2, 5, 6, 7), function(tp) {
  q <- quantile(x10, c(0.25, 0.75), type = tp)
  c(Q1 = unname(q[1]), Q3 = unname(q[2]), IQR = unname(q[2] - q[1]))
}) -> comp_tipos
colnames(comp_tipos) <- paste0("tipo ", c(2, 5, 6, 7))
print(comp_tipos)

# Efeito do divisor da variância: R usa n-1; n daria valor diferente
cat("var() do R (n-1):", var(x10), "| variância com divisor n:", var10_pop, "\n")

```

Saída (verificação):

```

instant  dteday casual registered total_user
1      72 2011-03-13   982      1435      2417
2      73 2011-03-14   359      1687      2046
3      74 2011-03-15   289      1767      2056
4      75 2011-03-16   321      1871      2192
5      76 2011-03-17   424      2320      2744
6      77 2011-03-18   884      2355      3239
7      78 2011-03-19  1424      1693      3117
8      79 2011-03-20  1047      1424      2471
9      80 2011-03-21   401      1676      2077
10     81 2011-03-22   460      2243      2703
Soma = 25062 | Média manual = 2506.2
Ordenado: 2046 2056 2077 2192 2417 2471 2703 2744 3117 3239
Mediana manual = 2444
Moda (10 obs.): NA
Soma dos quadrados dos desvios = 1711946
Variância amostral manual = 190216.2
Desvio padrão amostral manual = 436.1378
Variância populacional = 171194.6 | DP populacional = 413.7566
Q1 = 2105.75 | Q2 = 2444 | Q3 = 2733.75 | IQR = 628
Limites: 1163.75 e 3675.75

```

Outliers:

Mediana das metades: Q1 = 2077 | Q3 = 2744

Dias com total_user < Q1 (10 obs.): 3 de 10

	medida	manual	R	diferença
	Média	2506.2000	2506.2000	0
	Mediana	2444.0000	2444.0000	0
	Variância (n-1)	190216.1778	190216.1778	0
	Desvio padrão (n-1)	436.1378	436.1378	0
	Q1	2105.7500	2105.7500	0
	Q2	2444.0000	2444.0000	0
	Q3	2733.7500	2733.7500	0
	IQR	628.0000	628.0000	0

	tipo 2	tipo 5	tipo 6	tipo 7
Q1	2077	2077	2071.75	2105.75
Q3	2744	2744	2837.25	2733.75
IQR	667	667	765.50	628.00

var() do R (n-1): 190216.2 | variância com divisor n: 171194.6

Comparação manual × R: As medidas coincidem: média 2506,2, mediana 2444, var() = 190.216,18, sd() = 436,14, $Q_1 = 2105,75$, $Q_3 = 2733,75$ e $IQR = 628$. Isso ocorre porque o R usa por padrão exatamente as convenções adotadas no cálculo manual: divisor $n - 1$ na variância e `quantile(type = 7)`. Diferenças aparecem quando se muda a convenção:

Convenção	Q_1	Q_3	IQR
R padrão (tipo 7, interpolação em $(n - 1)p + 1$)	2105,75	2733,75	628
Tipo 6 (posição $(n + 1)p$, usada em Minitab/SPSS)	2071,75	2837,25	765,5
Mediana das metades (Tukey; tipos 2 e 5 aqui)	2077	2744	667

Também há diferença se a variância for calculada com divisor n (populacional, como em VAR.P do Excel): 171.194,56 (desvio padrão 413,76), cerca de 10% menor que a amostral. Como a amostra de 10 dias é pequena e o intervalo entre valores vizinhos é grande, a escolha do método muda os quartis de forma perceptível; com 300 observações a diferença praticamente desaparece (Q_1 varia de 3129,75 a 3137,25 e Q_3 de 4681 a 4685 entre os tipos 6 e 7).

2.3 Medidas de tendência central e dispersão (300 observações)

Verificado o código com as 10 observações, ele foi aplicado às 300 (funções `resumo_descritivo` e `calcular_moda`).

Código em R:

```
resumo_descritivo <- function(x) {
  q <- quantile(x, c(0.25, 0.5, 0.75))
  iqr <- q[3] - q[1]
  c(n = length(x), media = mean(x), mediana = median(x),
    dp = sd(x), variancia = var(x), minimo = min(x), maximo = max(x),
    Q1 = unname(q[1]), Q2 = unname(q[2]), Q3 = unname(q[3]), IQR = unname(iqr),
    lim_inf = unname(q[1] - 1.5 * iqr), lim_sup = unname(q[3] + 1.5 * iqr))
}

cat("\n--- 10 primeiras observações ---\n")
print(round(resumo_descritivo(x10), 2))
```

```
x300 <- data_group$total_user
cat("\n--- 300 observações ---\n")
res300 <- resumo_descritivo(x300)
print(round(res300, 3))

# Medidas de tendência central e dispersão (300 obs.)
media300 <- mean(x300)
mediana300 <- median(x300)
modas300 <- calcular_moda(x300)
cat("Média:", media300, "| Mediana:", mediana300, "\n")
cat("Modas (", length(modas300), " valores empatados):", modas300, "\n")
cat("Coeficiente de variação:", round(100 * sd(x300) / media300, 1), "%\n")
```

Saída:

```
--- 10 primeiras observações ---
      n      media      mediana      dp  variancia      minimo      maximo      Q1
10.00  2506.20  2444.00    436.14 190216.18    2046.00    3239.00    2105.75
      Q2      Q3      IQR    lim_inf    lim_sup
2444.00  2733.75    628.00   1163.75   3675.75

--- 300 observações ---
      n      media      mediana      dp  variancia      minimo
300.000  3839.980  4070.500   1113.816 1240585.244    627.000
maximo      Q1      Q2      Q3      IQR    lim_inf
6043.000  3137.250  4070.500   4681.000   1543.750    821.625
lim_sup
6996.625
Média: 3839.98 | Mediana: 4070.5
Modas ( 11 valores empatados): 3068 3351 3974 4098 4195 4274 4401 4758 5119 5202 5312
Coeficiente de variação: 29 %
```

Interpretação:

- **Média = 3839,98:** centro de massa da distribuição; em média, o sistema teve cerca de 3840 usuários por dia.
- **Mediana = 4070,5:** metade dos dias teve até esse número de usuários; é robusta a valores extremos.
- **Moda:** 11 valores diferentes aparecem exatamente duas vezes (3068, 3351, 3974, 4098, 4195, 4274, 4401, 4758, 5119, 5202 e 5312), então a variável é **multimodal e a moda não é informativa** para dados de contagem tão dispersos; a classe modal do histograma (4000 a 5000) é mais útil. O valor devolvido por uma rotina de moda depende de como ela resolve empates.
- **Dispersão:** desvio padrão = 1113,82 (coeficiente de variação $\approx 29\%$), mínimo = 627, máximo = 6043, amplitude = 5416.
- Como a média (3839,98) é menor que a mediana (4070,5), há indício de **assimetria à esquerda**, isto é, poucos dias de uso muito baixo puxam a média para baixo. O coeficiente de assimetria ($\approx -0,69$) confirma uma assimetria moderada.

2.4 Quartis, IQR e valores atípicos (300 observações)

Escolheu-se `total_user` por ser a medida-síntese da demanda do sistema (soma dos dois perfis de usuário), sobre a qual o critério `low_usage` é definido.

Código em R:

```

Q1 <- quantile(x300, 0.25); Q2 <- quantile(x300, 0.50); Q3 <- quantile(x300, 0.75)
IQR_total <- Q3 - Q1
lim_inf <- Q1 - 1.5 * IQR_total
lim_sup <- Q3 + 1.5 * IQR_total
cat("Q1 =", Q1, "| Q2 =", Q2, "| Q3 =", Q3, "| IQR =", IQR_total,
    "\nLimite inferior =", lim_inf, "| Limite superior =", lim_sup, "\n")

outliers <- subset(data_group, total_user < lim_inf | total_user > lim_sup,
    select = c(instant, dteday, weathersit, total_user))
print(outliers)
cat("Número de outliers:", nrow(outliers), "\n")

# Sensibilidade à convenção de quartil (300 obs.)
sapply(c(2, 5, 6, 7), function(tp) quantile(x300, c(0.25, 0.75), type = tp))

```

Saída:

```

Q1 = 3137.25 | Q2 = 4070.5 | Q3 = 4681 | IQR = 1543.75
Limite inferior = 821.625 | Limite superior = 6996.625
  instant      dteday weathersit total_user
106      106 2011-04-16          3         795
302      302 2011-10-29          3         627
341      341 2011-12-07          3         705
359      359 2011-12-25          1         754
Número de outliers: 4
      [,1] [,2] [,3] [,4]
25% 3133.5 3133.5 3129.75 3137.25
75% 4683.0 4683.0 4685.00 4681.00

```

Conclusão: $Q_1 = 3137,25$; $Q_2 = 4070,5$; $Q_3 = 4681$; $IQR = 1543,75$. Os limites são $3137,25 - 1,5 \cdot 1543,75 = 821,625$ (inferior) e $4681 + 1,5 \cdot 1543,75 = 6996,625$ (superior). Foram encontrados **4 valores atípicos, todos abaixo do limite inferior**:

Data	weathersit	total_user
2011-04-16	3 (chuva fraca)	795
2011-10-29	3 (chuva fraca)	627
2011-12-07	3 (chuva fraca)	705
2011-12-25	1 (céu limpo)	754

Três dos quatro dias ocorreram com chuva fraca, e o quarto é o feriado de Natal, sugerindo que clima adverso e feriados derrubam a demanda de forma marcante. Esses dias não devem ser descartados: são informativos sobre a sensibilidade do sistema a fatores externos. Não há outliers superiores (máximo = 6043).

2.5 Histograma e boxplot

Código em R:

```

png("Rplot01.png", width = 1200, height = 500, res = 120)
par(mfrow = c(1, 2))
hist(x300, breaks = seq(0, 7000, by = 1000), right = FALSE,
     col = "lightblue", border = "white",
     main = "Histograma de total_user", xlab = "Usuários por dia", ylab =
     ↪ "Frequência")
abline(v = c(media300, mediana300), col = c("red", "darkgreen"), lwd = 2, lty = c(2,
     ↪ 1))

```

```

legend("topleft", legend = c("Média", "Mediana"), col = c("red", "darkgreen"),
      lwd = 2, lty = c(2, 1), bty = "n", cex = 0.8)
boxplot(x300, horizontal = TRUE, col = "lightblue",
      main = "Boxplot de total_user", xlab = "Usuários por dia")
dev.off()

# Contagem por classe
table(cut(x300, breaks = seq(0, 7000, by = 1000), right = FALSE))

# Assimetria
assim <- mean((x300 - media300)^3) / sd(x300)^3
cat("Coeficiente de assimetria (momento):", round(assim, 3), "\n")

```

Saída:

```

[0,1e+03) [1e+03,2e+03) [2e+03,3e+03) [3e+03,4e+03) [4e+03,5e+03)
      4          17          47          74          123
[5e+03,6e+03) [6e+03,7e+03)
      34          1
Coeficiente de assimetria (momento): -0.684

```

Gráficos:




Figura 1: Histograma e boxplot de total_user.

Interpretação: O histograma (classes de 1000 usuários) tem uma moda clara na classe 4000–5000, com 123 dias, seguida de 3000–4000 (74 dias) e 5000–6000 (34 dias); as classes de baixo uso (0–1000, 1000–2000 e 2000–3000) somam 68 dias e formam a cauda esquerda, o que evidencia a assimetria negativa e a diferença entre média e mediana. O boxplot mostra a mediana deslocada para a direita dentro da caixa, o bigode inferior mais longo e os 4 pontos isolados abaixo de 821,625, sem pontos acima de 6996,625. **O histograma é melhor para a forma da distribuição** (concentração, cauda, assimetria), e **o boxplot para quartis, IQR e outliers**, resumindo a dispersão de forma compacta.

2.6 Variável low_usage

Definida por $\text{low_usage} = 1$ se $\text{total_user} < Q_1$, e 0 caso contrário.

Código em R:

```

data_group$low_usage <- ifelse(data_group$total_user < Q1, 1, 0)
cat("Q1 =", Q1, "\n")
cat("Dias de baixa utilização:", sum(data_group$low_usage), "\n")
cat("Proporção:", mean(data_group$low_usage), "\n")
table(data_group$low_usage)

```

Saída:

Q1 = 3137.25
Dias de baixa utilização: 75
Proporção: 0.25

0	1
225	75

Conclusão: Com $Q_1 = 3137,25$, **75 dias** foram classificados como de baixa utilização, o que corresponde a **25%** da amostra (75/300), como esperado pela definição de primeiro quartil. O critério identifica o quarto de dias com menor demanda e servirá de base para investigar quais fatores climáticos e sazonais estão associados a esses dias.

Questão 3: Características associadas aos dias de baixa utilização

Esta questão tem como objetivo investigar quais características do conjunto de dados estão mais associadas aos dias de baixa utilização do sistema, identificadas pela variável binária `low_usage` definida na Questão 2 (com base no primeiro quartil, $Q_1 = 3137,25$). Para isso, o `data_group` construído na Questão 1 foi analisado sob três perspectivas: a sazonalidade (estação do ano), as condições meteorológicas e a temperatura. Em cada uma delas, calculam-se medidas de tendência central e de dispersão de `total_user`, além da proporção de dias classificados como `low_usage`, complementando a análise com gráficos comparativos (boxplots, gráfico de dispersão e gráfico de barras). Ao final, as evidências estatísticas e gráficas levantadas são utilizadas para selecionar, de forma justificada, as duas características mais fortemente associadas à utilização do sistema.

3.1 Análise da utilização por estação do ano

Esta etapa compara a distribuição de `total_user` entre as quatro estações do ano presentes no `data_group`, usando a variável binária `low_usage` definida na Questão 2 ($Q_1 = 3137,25$). Para cada estação, calcularam-se a média, a mediana, o desvio padrão amostral e a proporção de dias de baixa utilização. Em seguida, construiu-se um boxplot comparativo. Foram usadas apenas funções do R base (`factor`, `tapply`, `boxplot` e `aggregate`).

Codificação das estações: o enunciado lista as estações na ordem “primavera, verão, outono e inverno”, mas as datas da amostra mostram outra correspondência. A estação 1 cobre 13/03/2011–20/03/2011 e 21/12/2011–06/01/2012. A estação 2 vai de 21/03 a 20/06, a 3 de 21/06 a 22/09 e a 4 de 23/09 a 20/12. Seguindo os solstícios e equinócios do Hemisfério Norte, adotou-se: 1 = Inverno, 2 = Primavera, 3 = Verão, 4 = Outono.

Cálculo manual (10 primeiras observações): as 10 primeiras observações (13/03/2011 a 22/03/2011) ficam em apenas duas estações: 8 dias no Inverno e 2 na Primavera. As fórmulas usadas foram:

- Média: $\bar{x} = (\sum x_i)/n$
- Mediana: valor central da amostra ordenada; com n par, é a média dos dois valores centrais.
- Desvio padrão amostral: $s = \sqrt{\sum (x_i - \bar{x})^2 / (n - 1)}$

- Proporção de baixa utilização: $p = (n^o \text{ de dias com total_user} < 3137,25)/n$

Inverno ($n = 8$): 2417, 2046, 2056, 2192, 2744, 3239, 3117, 2471

- $\sum x_i = 20282 \Rightarrow \bar{x} = 20282/8 = 2535,25$
- Ordenados: 2046, 2056, 2192, **2417**, **2471**, 2744, 3117, 3239 $\Rightarrow$ mediana = $(2417 + 2471)/2 = 2444$
- $\sum (x_i - \bar{x})^2 = 239365,56 + 229680,56 + 117820,56 + 13983,06 + 4128,06 + 43576,56 + 338433,06 + 495264,06 = 1482251,48$
- $s = \sqrt{1482251,48/7} = \sqrt{211750,21} = 460,16$
- Só o dia 18/03 (3239) fica acima de $Q_1 \Rightarrow p = 7/8 = 0,875$

Primavera ($n = 2$): 2077, 2703

- $\bar{x} = 4780/2 = 2390$; mediana = $(2077 + 2703)/2 = 2390$
- $\sum (x_i - \bar{x})^2 = (-313)^2 + (313)^2 = 195938 \Rightarrow s = \sqrt{195938/1} = 442,65$
- Os dois dias estão abaixo de $Q_1 \Rightarrow p = 2/2 = 1,00$

Código em R (300 observações e gráfico):

```
arquivo <- "https://raw.githubusercontent.com/marisalinhares/homework_1_estadistica/r_1/efs/heads/main/HW1_bike_sharing.csv"
dados_completos <- read.csv(arquivo)
if (ncol(dados_completos) == 1) dados_completos <- read.csv2(arquivo)

data_group <- dados_completos[72:371, ]
data_group$total_user <- as.numeric(data_group$casual) +
as.numeric(data_group$registered)
Q1 <- as.numeric(quantile(data_group$total_user, 0.25))
data_group$low_usage <- ifelse(data_group$total_user < Q1, 1, 0)

# conferindo apenas
print(nrow(data_group))
print(Q1)
print(sum(data_group$low_usage))

# Questao 3.1
data_group$estacao <- factor(data_group$season, levels = c(1, 2, 3, 4), labels =
c("Inverno", "Primavera", "Verao", "Outono"))
data_group_10 <- data_group[1:10, ]

#10 primeir
print(aggregate(total_user ~ estacao, data = data_group_10, FUN = mean))
print(aggregate(total_user ~ estacao, data = data_group_10, FUN = median))
print(aggregate(total_user ~ estacao, data = data_group_10, FUN = sd))
print(aggregate(low_usage ~ estacao, data = data_group_10, FUN = mean))

#300 ob
print(aggregate(total_user ~ estacao, data = data_group, FUN = mean))
print(aggregate(total_user ~ estacao, data = data_group, FUN = median))
print(aggregate(total_user ~ estacao, data = data_group, FUN = sd))
print(aggregate(low_usage ~ estacao, data = data_group, FUN = mean))
```

```
print(table(data_group$estacao))

#boxplot
boxplot(total_user ~ estacao, data = data_group,
        main = "Total de usuários por estação do ano",
        xlab = "Estação", ylab = "Total de usuários por dia",
        col = c("lightblue", "lightgreen", "khaki", "salmon"))
abline(h = Q1, lty = 2, col = "red")
```

Segue a saída do código (300 observações):

```
estacao total_user (Média)
1 Inverno 2355.640
2 Primavera 3775.174
3 Verao 4464.362
4 Outono 3664.461

estacao total_user (Mediana)
1 Inverno 2368.0
2 Primavera 4085.5
3 Verao 4615.5
4 Outono 3717.0

estacao total_user (Desvio Padrão)
1 Inverno 756.4824
2 Primavera 1138.9010
3 Verao 798.3481
4 Outono 983.0061

estacao low_usage (Proporção)
1 Inverno 0.88000000
2 Primavera 0.27173913
3 Verao 0.04255319
4 Outono 0.26966292
```




Figura 2: Total de usuários por estação do ano.

Explicação do código e Interpretação: A utilização do sistema varia bastante entre as estações. O Verão tem a maior média (4464,36 usuários) e a maior mediana

(4615,5), e apenas 4,26% dos seus dias são de baixa utilização (`low_usage`). No boxplot, a distribuição do Verão fica quase toda acima da linha tracejada vermelha, que marca Q_1 . O Inverno está no extremo oposto: média de 2355,64 e 88% dos dias classificados como de baixa utilização, com a caixa abaixo da linha de Q_1 .

A Primavera e o Outono têm perfis intermediários e parecidos, ambos com cerca de 27% de dias de baixa utilização (27,2% e 27,0%). A Primavera é a estação com maior dispersão, com desvio padrão de 1138,90, o maior entre as quatro. O boxplot também mostra pontos isolados (*outliers* dentro de cada estação): dias de demanda alta para o padrão do Inverno e dias de demanda baixa para o Verão e o Outono.

3.2 Análise da utilização em função das condições meteorológicas

Cálculo manual (10 primeiras observações): nas 10 primeiras observações (13/03/2011 a 22/03/2011), a variável `weathersit` apresenta apenas duas categorias: 7 dias de Céu Limpo e 3 dias de Nublado. Não há nenhum dia de Chuva Fraca nesse subconjunto. As fórmulas usadas foram as mesmas da Seção 3.1 (média, desvio padrão amostral e proporção de baixa utilização).

Céu Limpo ($n = 7$): 2417, 2046, 2744, 3239, 3117, 2471, 2703

- $\sum x_i = 18737 \Rightarrow \bar{x} = 18737/7 = 2676,71$
- $\sum (x_i - \bar{x})^2 = 1022805,43 \Rightarrow s = \sqrt{1022805,43/6} = \sqrt{170467,57} = 412,88$
- 6 dos 7 dias ficam abaixo de Q_1 (3137,25) $\Rightarrow p = 6/7 = 0,857$

Nublado ($n = 3$): 2056, 2192, 2077

- $\sum x_i = 6325 \Rightarrow \bar{x} = 6325/3 = 2108,33$
- $\sum (x_i - \bar{x})^2 = 10720,67 \Rightarrow s = \sqrt{10720,67/2} = \sqrt{5360,33} = 73,21$
- Todos os 3 dias ficam abaixo de $Q_1 \Rightarrow p = 3/3 = 1,00$

Código em R:

```
# Transforma a variavel numerica 'weathersit' num fator com rotulos
# compreensíveis
data_group$clima <- factor(data_group$weathersit,
                           levels = c(1, 2, 3),
                           labels = c("Ceu Limpo", "Nublado", "Chuva Fraca"))

data_group_10 <- data_group[1:10, ]

# 10 primeiras observacoes
print("Média de usuários por clima (10 primeiras observações):")
aggregate(total_user ~ clima, data = data_group_10, FUN = mean)

print("Desvio padrão de usuários por clima (10 primeiras observações):")
aggregate(total_user ~ clima, data = data_group_10, FUN = sd)

print("Proporção de dias de baixa utilização por clima (10 primeiras observações):")
aggregate(low_usage ~ clima, data = data_group_10, FUN = mean)

print("Frequência de dias na amostra (10 primeiras observações):")
table(data_group_10$clima)
```

```

# 300 observacoes
print("Média de usuários por clima:")
aggregate(total_user ~ clima, data = data_group, FUN = mean)

print("Desvio padrão de usuários por clima:")
aggregate(total_user ~ clima, data = data_group, FUN = sd)

print("Proporção de dias de baixa utilização por clima:")
aggregate(low_usage ~ clima, data = data_group, FUN = mean)

print("Frequência de dias na amostra:")
table(data_group$clima)

# Gráfico 1: boxplot para comparar a distribuição de total_user
boxplot(total_user ~ clima, data = data_group,
        main = "Total de usuários por Condição Meteorológica",
        xlab = "Condição do Tempo",
        ylab = "Total de usuários por dia",
        col = c("skyblue", "lightgray", "steelblue"))
abline(h = Q1, lty = 2, col = "red")

# Gráfico 2: gráfico de barras da proporção de low_usage por clima
prop_clima <- aggregate(low_usage ~ clima, data = data_group, FUN = mean)
barplot(prop_clima$low_usage, names.arg = prop_clima$clima,
        main = "Proporção de low_usage por Condição Meteorológica",
        xlab = "Condição do Tempo",
        ylab = "Proporção de dias low_usage",
        col = c("skyblue", "lightgray", "steelblue"),
        ylim = c(0, 1))

```

Segue a saída do código:

```

[1] "Média de usuários por clima (10 primeiras observações):"
clima total_user
1 Ceu Limpo    2676.714
2 Nublado      2108.333

[1] "Desvio padrão de usuários por clima (10 primeiras observações):"
clima total_user
1 Ceu Limpo    412.8772
2 Nublado       73.2143

[1] "Proporção de dias de baixa utilização por clima (10 primeiras observações):"
clima low_usage
1 Ceu Limpo 0.8571429
2 Nublado  1.0000000

[1] "Frequência de dias na amostra (10 primeiras observações):"
Ceu Limpo  Nublado Chuva Fraca
      7      3      0

[1] "Média de usuários por clima:"
clima total_user
1 Ceu Limpo    4131.836
2 Nublado      3541.776
3 Chuva Fraca  1844.846

[1] "Desvio padrão de usuários por clima:"
clima total_user

```

```

1 Ceu Limpo      988.8999
2 Nublado        1034.0396
3 Chuva Fraca    753.2358

```

```

[1] "Proporção de dias de baixa utilização por clima:"
clima low_usage

```

```

1 Ceu Limpo      0.1587302
2 Nublado        0.3265306
3 Chuva Fraca    1.0000000

```

```

[1] "Frequência de dias na amostra:"

```

```

Ceu Limpo  Nublado  Chuva Fraca
    189      98      13

```




Figura 3: Total de usuários por condição meteorológica.




Figura 4: Proporção de low_usage por condição meteorológica.

Explicação e Interpretação: Nas 10 primeiras observações, apenas as condições Céu Limpo (7 dias) e Nublado (3 dias) estão presentes, sem nenhum dia de Chuva Fraca.

Nesse subconjunto, os dias de Céu Limpo já apresentam média de 2676,71 usuários e 85,7% de proporção de `low_usage`, enquanto os 3 dias Nublados têm média de 2108,33 e 100% de baixa utilização — valores mais extremos do que os observados na amostra completa, o que reforça que esse subconjunto de 10 dias não é representativo do padrão geral.

Na amostra completa, os dias de Céu Limpo são maioria (189 dias) e têm a maior média (4131,83 usuários por dia) e a menor proporção de dias de baixa utilização (`low_usage`), cerca de 15,87%.

À medida que o tempo piora, a demanda cai. Nos dias Nublados, a média é de 3541,77 usuários e a proporção de `low_usage` passa de 32%, cerca do dobro da observada no Céu Limpo. Nos dias de Chuva Fraca, que são apenas 13 na amostra, a média cai para 1844,84. O boxplot mostra toda a distribuição de Chuva Fraca abaixo de Q_1 , o que explica a proporção de 100% (1,0) de dias `low_usage` nessa condição. O gráfico de barras exibe a progressão de aproximadamente 16% (Céu Limpo) para 33% (Nublado) e 100% (Chuva Fraca). Assim, quanto pior a condição meteorológica, menor a utilização do sistema de compartilhamento de bicicletas.

3.3 Relação entre a temperatura e a utilização do sistema

Cálculo manual (10 primeiras observações):

Dia	temp_norm (x)	total_user (y)
13/03	0,3854	2417
14/03	0,3244	2046
15/03	0,3171	2056
16/03	0,3659	2192
17/03	0,4146	2744
18/03	0,5390	3239
19/03	0,4732	3117
20/03	0,3317	2471
21/03	0,4293	2077
22/03	0,4415	2703

$$\bar{x} = 0,4022; \quad \bar{y} = 2506,2$$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 232,22$$

$$\sum (x_i - \bar{x})^2 = 0,04606 \rightarrow \sqrt{\quad} = 0,2146$$

$$\sum (y_i - \bar{y})^2 = 1\,711\,953,60 \rightarrow \sqrt{\quad} = 1308,41$$

$$r = \frac{232,22}{0,2146 \times 1308,41} = \mathbf{0,827}$$

O valor de r permanece idêntico ao calculado com a temperatura em graus Celsius, pois o coeficiente de correlação de Pearson é invariante a transformações lineares como a divisão por uma constante.

Código em R:

```
# Cria a variavel normalizada (Celsius / 41), conforme definido no enunciado
data_group$temp_norm <- data_group$temp / 41

# Seleciona as 10 primeiras observacoes
data_group_10 <- data_group[1:10, ]

# Calcula o coeficiente de correlação (Pearson) - 10 primeiras observações
print("Coeficiente de correlação entre Temperatura e Total de Usuários (10
primeiras observações):")
correlacao_10 <- cor(data_group_10$temp_norm, data_group_10$total_user)
print(correlacao_10)

# Calcula o coeficiente de correlação (Pearson) - 300 observações
print("Coeficiente de correlação entre Temperatura e Total de Usuários:")
correlacao <- cor(data_group$temp_norm, data_group$total_user)
print(correlacao)

# Constrói o gráfico de dispersão (Scatter plot)
plot(data_group$temp_norm, data_group$total_user,
      main = "Relação entre Temperatura e Utilização do Sistema",
      xlab = "Temperatura Normalizada",
      ylab = "Total de usuários por dia",
      col = "darkorange",
      pch = 16) # pch = 16 deixa os pontos preenchidos (bolinhas)

# linha de tendência para visualizar melhor a relação
abline(lm(total_user ~ temp_norm, data = data_group), col = "blue", lwd = 2)
```

Segue a saída do código:

```
[1] "Coeficiente de correlação entre Temperatura e Total de Usuários (10
primeiras observações):"
[1] 0.8269468

[1] "Coeficiente de correlação entre Temperatura e Total de Usuários:"
[1] 0.6315909
```




Figura 5: Relação entre temperatura normalizada e total_user.

Explicação e Interpretação: O coeficiente de correlação de Pearson foi de aproximadamente 0,63 para as 300 observações, o que indica uma associação linear positiva

de intensidade moderada a forte entre a temperatura e a utilização do sistema. Em geral, o total de usuários por dia aumenta com a temperatura, como mostra a inclinação ascendente da linha de tendência no gráfico de dispersão.

Contudo, o coeficiente de Pearson mede apenas a força de relações lineares, e o gráfico sugere que a relação não é linear em toda a faixa de temperatura. Para valores mais altos (acima de 0,73 normalizado, cerca de 30 °C), o total de usuários parece estagnar e até diminuir ligeiramente, o que pode indicar que o calor extremo desestimula o uso das bicicletas. Como a relação apresenta essa não linearidade nos extremos, o coeficiente linear não captura toda a complexidade da relação entre a temperatura e a demanda do sistema.

3.4 Seleção e justificativa das características mais associadas à utilização do sistema

Justificativa: Com base nas análises desta seção, selecionam-se as Condições Meteorológicas e a Temperatura como as duas características mais associadas à utilização do sistema de compartilhamento de bicicletas. A Estação do Ano também apresentou associação forte (Seção 3.1) e não foi descartada por ter efeito pequeno, e sim por ser redundante com a temperatura, como explicado a seguir.

Temperatura. O coeficiente de Pearson de 0,63 corresponde a $r^2 \approx 0,40$, ou seja, cerca de 40% da variação de `total_user` acompanha linearmente a temperatura. O gráfico de dispersão mostra tendência ascendente até aproximadamente 30 °C (0,73 em temperatura normalizada), a partir da qual a demanda estagna. Como a temperatura tende a acompanhar o ciclo das estações, ela representa o efeito sazonal de forma contínua (Verão: média de 4464,36 usuários e 4,26% de dias `low_usage`; Inverno: média de 2355,64 e 88%), com mais detalhe do que as quatro categorias de estação. Manter as duas variáveis seria, em grande parte, contar o mesmo efeito duas vezes.

Condições meteorológicas. Essa variável descreve um fator diferente da temperatura e do calendário. Os dias de Chuva Fraca têm média de 1844,8 usuários, contra 4131,8 nos dias de Céu Limpo (queda de cerca de 55%), e todos os 13 dias de Chuva Fraca foram de baixa utilização (`low_usage`). A proporção de `low_usage` cresce de forma consistente com a piora do tempo (16% no Céu Limpo, 33% no Nublado e 100% na Chuva Fraca), embora o resultado para Chuva Fraca se apoie em apenas 13 dias.

Questão 4: Síntese e Aprofundamento da Análise

Essa parte, como requisito, utiliza em conjunto os resultados obtidos nas Questões 2 e 3 para aperfeiçoar a análise do sistema de compartilhamento de bicicletas, revisitando as características selecionadas e consolidando as principais conclusões do trabalho.

4.1 Série Temporal de Utilização

Para identificar os principais padrões temporais do sistema, construiu-se a série temporal de `total_user` ao longo dos 300 dias do `data_group`.

Código em R:

```
data_group$dia_idx <- 1:300
```

```
plot(data_group$dia_idx, data_group$total_user, type = "l",
     main = "Série Temporal de Total de Usuários (300 dias)",
     xlab = "Dia (índice sequencial)", ylab = "Total de usuários por dia",
     col = "darkblue")
abline(h = Q1, lty = 2, col = "red")

# picos e quedas
data_group[order(-data_group$total_user), c("dteday", "total_user")][1:5,]
data_group[order(data_group$total_user), c("dteday", "total_user")][1:5,]
```




Figura 6: Série temporal de `total_user` ao longo dos 300 dias observados. A linha tracejada vermelha indica o valor de Q_1 (3137,25).

Explicação: A série mostra um padrão sazonal ao longo do período observado. O pico de utilização ocorre em 04/07/2011 (6043 usuários), no Verão, e o menor valor da amostra é de 29/10/2011 (627 usuários), em um dia de Chuva Fraca no Outono. Destaca-se também a queda de 25/12/2011 (754 usuários), coincidente com o feriado de Natal. A série cresce do Inverno para a Primavera e o Verão e diminui do Verão para o Outono e o Inverno seguinte, o que reforça o papel do clima e das condições meteorológicas, apontados na Questão 3 como centrais para a demanda.

4.2 Aprofundamento das Características Seleccionadas na Questão 3

As duas características seleccionadas na Questão 3.4 (condições meteorológicas e temperatura) foram revisitadas nessa seção com visualizações e medidas estatísticas distintas das utilizadas anteriormente.

4.2.1 Condições meteorológicas. Em complemento ao boxplot e ao gráfico de barras da Questão 3.2, construiu-se um gráfico de densidade de `total_user` por condição meteorológica e aplicou-se uma *Análise de Variância* (ANOVA) para quantificar a proporção da variância explicada pela variável `weathersit`.

Código em R:

```

d_ceu <- density(data_group$total_user[data_group$clima == "Ceu Limpo"])
d_nub <- density(data_group$total_user[data_group$clima == "Nublado"])
d_chu <- density(data_group$total_user[data_group$clima == "Chuva Fraca"])
plot(d_ceu, col = "skyblue", lwd = 2, main = "Densidade de total_user por Condição
↪ Meteorológica",
     xlab = "Total de usuários por dia", ylim = c(0, max(d_ceu$y, d_nub$y, d_chu$y)))
lines(d_nub, col = "gray50", lwd = 2); lines(d_chu, col = "steelblue4", lwd = 2)
legend("topright", legend = c("Céu Limpo", "Nublado", "Chuva Fraca"),
      col = c("skyblue", "gray50", "steelblue4"), lwd = 2)

anova_clima <- aov(total_user ~ clima, data = data_group)
summary(anova_clima)

```




Figura 7: Densidade de total_user por condição meteorológica.

Explicação e Interpretação: A ANOVA resultou em $F = 38,62$ com $p < 0,001$, indicando diferença estatisticamente significativa entre as médias de **total_user** nas três condições meteorológicas. O coeficiente $\eta^2 = 0,206$ mostra que aproximadamente 20,6% da variância total de **total_user** é explicada apenas considerando a condição meteorológica. As curvas de densidade confirmam o padrão observado previamente na Questão 3.2: a distribuição de Chuva Fraca se concentra em valores mais baixos e com menor dispersão, enquanto Céu Limpo apresenta a distribuição deslocada para valores mais altos de usuários, corroborando de forma quantitativa a força dessa associação.

4.2.2 Temperatura. Além do gráfico de dispersão e do coeficiente de Pearson calculados na Questão 3.3, discretizou-se a variável **temp** em quatro faixas (quartis), comparadas por meio de boxplots, e calculou-se o coeficiente de correlação de Spearman, mais adequado a relações não estritamente lineares.

Código em R:

```

data_group$temp_bin <- cut(data_group$temp_norm,
  breaks = quantile(data_group$temp_norm, probs = c(0,0.25,0.5,0.75,1)),
  labels = c("Frio (Q1)", "Ameno (Q2)", "Quente (Q3)", "Muito Quente (Q4)"),
  include.lowest = TRUE)
boxplot(total_user ~ temp_bin, data = data_group,
  main = "Total de usuários por faixa de temperatura",
  xlab = "Faixa de temperatura normalizada", ylab = "Total de usuários por dia",

```

```
col = c("lightblue","lightgreen","gold","salmon"))

cor(data_group$temp_norm, data_group$total_user, method = "spearman")
```




Figura 8: Total de usuários por faixa de temperatura normalizada (quartis).

Explicação e Interpretação: O boxplot por faixas de temperatura mostra crescimento consistente da mediana de `total_user` da faixa Frio até a faixa Quente, com estabilização entre as faixas Quente e Muito Quente. O coeficiente de Spearman ($\rho = 0,631$) é praticamente idêntico ao coeficiente de Pearson obtido na Questão 3.3 ($r = 0,6316$), o que indica que a relação entre temperatura e utilização é predominantemente monotônica, mesmo diante da leve não linearidade nos extremos já discutida anteriormente.

4.3 Relação entre Temperatura e Utilização por Grupo de `low_usage`

Para melhorar a análise da relação entre temperatura e utilização, construiu-se um gráfico de dispersão diferenciando visualmente os dias classificados como `low_usage = 1` dos demais.

Código em R:

```
cores <- ifelse(data_group$low_usage == 1, "red", "darkorange")
plot(data_group$temp_norm, data_group$total_user, col = cores, pch = 16,
      main = "Temperatura vs Total de Usuários, por low_usage",
      xlab = "Temperatura Normalizada", ylab = "Total de usuários por dia")
legend("topleft", legend = c("low_usage = 0", "low_usage = 1"), col =
  ↪ c("darkorange", "red"), pch = 16)

cor(data_group$temp_norm[data_group$low_usage==0],
  ↪ data_group$total_user[data_group$low_usage==0])
cor(data_group$temp_norm[data_group$low_usage==1],
  ↪ data_group$total_user[data_group$low_usage==1])
```




Figura 9: Temperatura normalizada vs. total_user, diferenciado por low_usage.

Explicação e Interpretação: A relação entre temperatura e utilização difere entre os dois grupos. Entre os dias com `low_usage = 0` ($n = 225$), o coeficiente de correlação é $r = 0,439$; entre os dias com `low_usage = 1` ($n = 75$), cai para $r = 0,166$. Isso indica que, nos dias já caracterizados por baixa utilização, a temperatura explica menos da variação da demanda, o que sugere que outros fatores, possivelmente as condições meteorológicas discutidas na Seção 4.2.1, tenham mais peso do que a temperatura nesses dias.

4.4 Conclusão Final

A análise integrada das Questões 2 a 4 evidencia que a utilização do sistema de compartilhamento de bicicletas apresenta forte componente sazonal e meteorológico. A série temporal de `total_user` revela um padrão sazonal bem definido ao longo do período observado, com pico no Verão (6043 usuários em 04/07/2011) e quedas acentuadas no Inverno e em dias de Chuva Fraca, incluindo o feriado de Natal (25/12/2011, 754 usuários). Entre as características investigadas na Questão 3, as condições meteorológicas e a temperatura mostraram-se as mais associadas à demanda. A ANOVA aplicada a `weathersit` ($F = 38,62$; $p < 0,001$) indica que essa variável explica aproximadamente 20,6% da variância de `total_user`, com a Chuva Fraca reduzindo a média diária para 1844,8 usuários e elevando a proporção de dias de baixa utilização para 100%. A temperatura mantém correlação positiva e robusta com a demanda (Pearson $r = 0,63$; Spearman $\rho = 0,63$), embora essa associação se enfraqueça nos dias já classificados como `low_usage` ($r = 0,17$, contra $r = 0,44$ nos demais), sugerindo que, nesses dias, fatores meteorológicos adversos predominam sobre o efeito da temperatura.